UNIVERSITÀ DEGLI STUDI DI TRIESTE

Robustezza e verifica formale di reti neurali

Confronto tra adversarial training e Marabou SMT su GTSRB

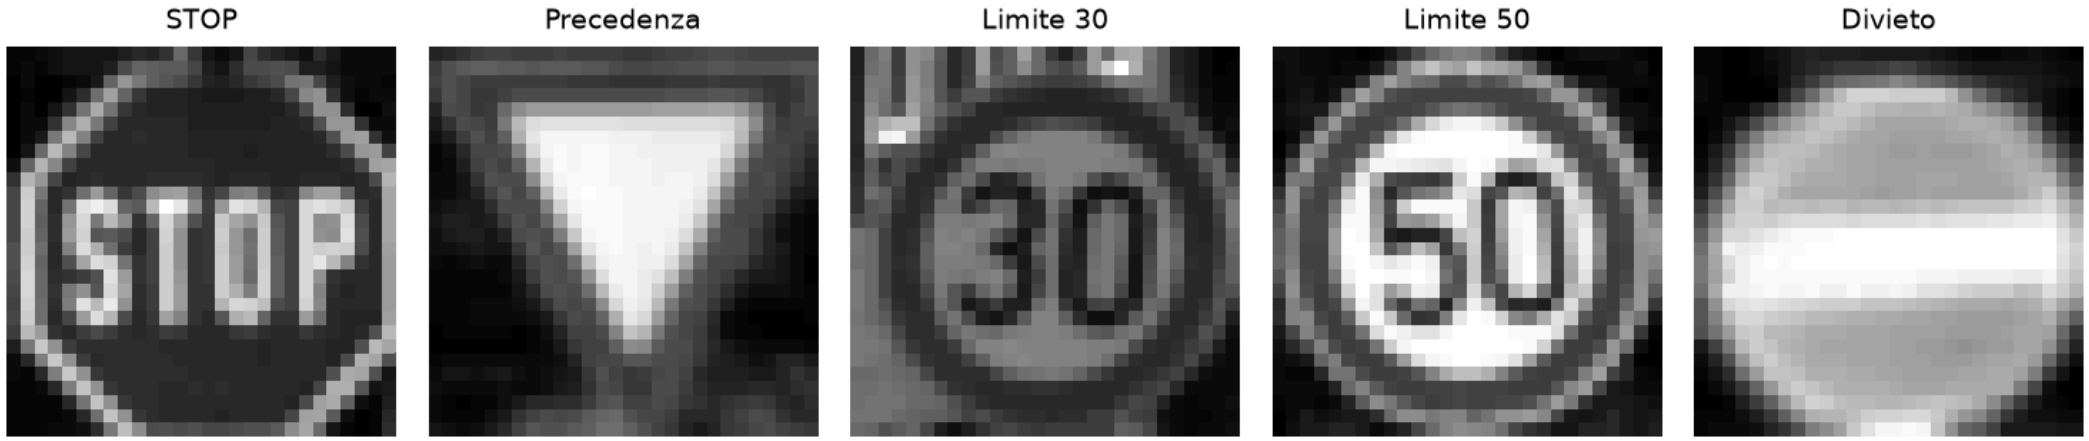
Giovanni Norbedo
Introduction to Machine Learning, 2025/2026
Università degli Studi di Trieste

Vulnerabilità avversaria e limiti dei test

In compiti critici come la guida autonoma, le reti neurali devono essere affidabili.

- **Vulnerabilità avversaria (L_∞)**: modifiche minime e impercettibili sui pixel ingannano sistematicamente le reti standard.
- **Il limite del testing empirico**: attacchi euristici come **PGD** esplorano il gradiente locale. Se non trovano un controesempio, non garantiscono che la rete sia sicura.
- **Verifica formale esatta**: con il solver SMT **Marabou** (Wu et al., 2024; Albarghouthi, 2021), dimostriamo matematicamente l'assenza di controesempi all'interno dell'ipercubo continuo $[x_0 - \epsilon, x_0 + \epsilon]$.

Dataset GTSRB e modello piecewise-linear



- **5 classi critiche**: STOP, Precedenza, Limite 30, Limite 50, Divieto.
- **Split bilanciato a tracce video disgiunte**: 3.000 train (600/classe), 500 val, 1.250 test. Evita il *data leakage* tra frame consecutivi.
- **MLP piecewise-linear (`TrafficSignNet`)**: 3 strati ($784 \to 64 \to 32 \to 5$) con 2 strati nascosti ReLU (96 nodi totali) ed export ONNX senza softmax.
- *Perché non una CNN?* I solver SMT completi richiedono vincoli lineari a tratti per risolvere con il simplesso senza esplosione combinatoria.

Adversarial training con PGD

Confronto tra le due strategie di addestramento:

Modello standard (ERM)

- Ottimizzazione classica della cross-entropy sui dati puliti.
- Nessuna perturbazione applicata durante il training.
- Accuratezza clean sul test set: **94.1%**.

Modello robusto (mixed AT)

- Addestramento con loss mista bilanciata:

$$\mathcal{L} = 0.4\mathcal{L}_{\text{clean}} + 0.6\mathcal{L}_{\text{adv}}$$

- Esempi avversari generati online con PGD ($\epsilon = 0.05$).
- Accuratezza clean sul test set: **93.3%**.

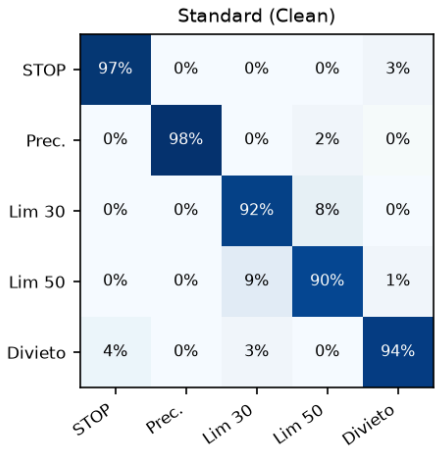
Valutazione empirica sotto attacco PGD

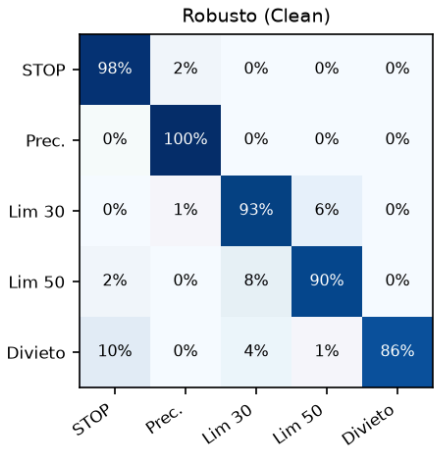
Accuratezza sul test set (1.250 immagini) sotto attacco PGD a 15 passi al variare di ϵ:

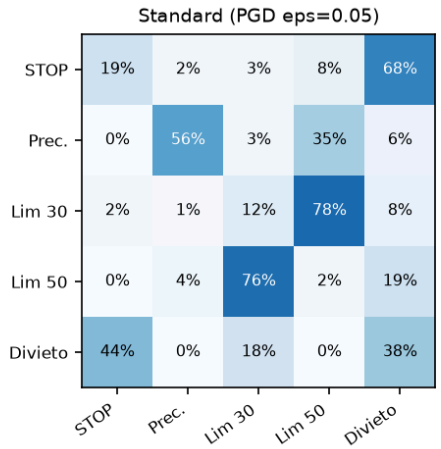
Epsilon ϵ	Modello standard	Modello robusto	Guadagno robusto (delta)
0.00 (clean)	94.1%	93.3%	-0.8%
0.01	76.6%	88.2%	**+11.6%**
0.02	60.0%	84.2%	**+24.2%**
0.03	46.8%	79.4%	**+32.6%**
0.05	25.5%	68.7%	**+43.2%**

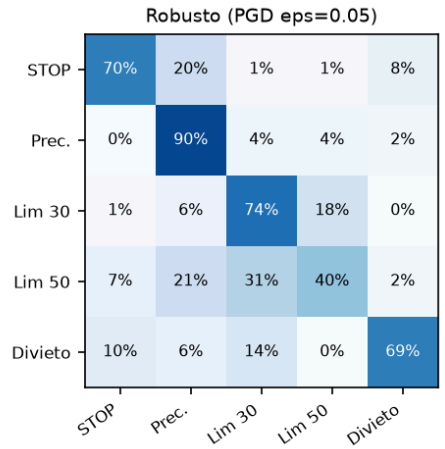
- Nessuna penalizzazione per il modello difeso (accuratezza preservata a ~93-94%).
- Mentre il modello standard crolla al 25.5% a $\epsilon = 0.05$, il modello robusto mantiene il 68.7% (**+43.2% netto**).

Matrici di confusione a confronto









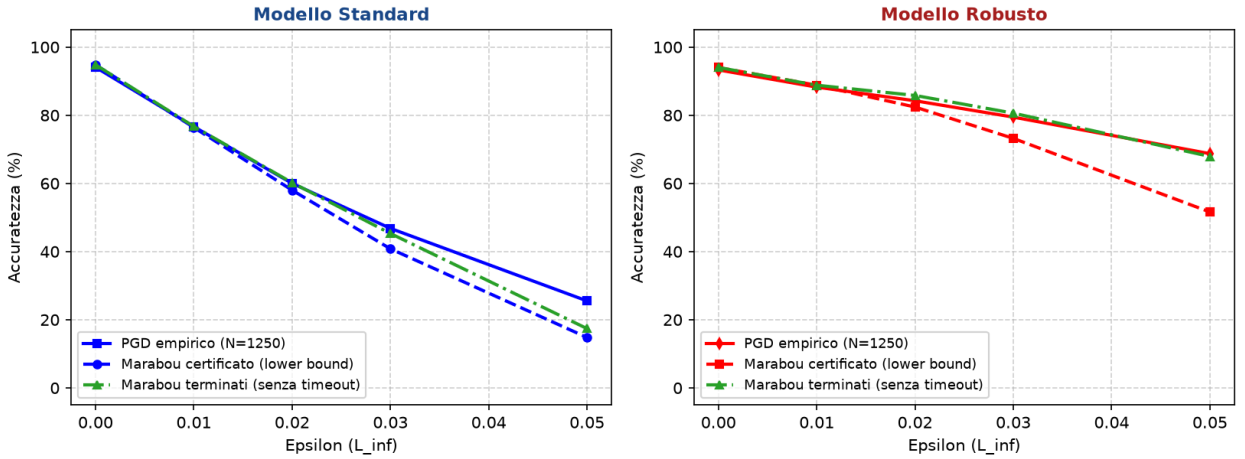
Verifica formale con Marabou SMT

Accuratezza certificata su 250 campioni bilanciati (timeout = 5s per query target):

Raggio ϵ	Standard: certificata	Robusto: certificata	Delta guadagno	Timeout standard	Timeout robusto
0.00	94.8%	94.0%	-0.8%	0.0%	0.0%
0.01	76.4%	88.8%	**+12.4%**	0.4%	0.0%
0.02	58.0%	82.4%	**+24.4%**	3.6%	4.0%
0.03	40.8%	73.2%	**+32.4%**	10.0%	9.2%
0.05	14.8%	51.6%	**+36.8%**	14.8%	24.0%

- **Criterio conservativo (soundness)**: i campioni in timeout sono conteggiati come non certificati per garantire un lower bound matematico formale.
- **Asimmetria dei timeout**: a $\epsilon = 0.05$ lo standard fallisce subito (70.4% **SAT** in <0.3s), mentre nel robusto i controesempi sono rari (24.4% SAT): il solver cerca di dimostrare **UNSAT** esaurendo il tempo sulle ReLU instabili (24.0% timeout).

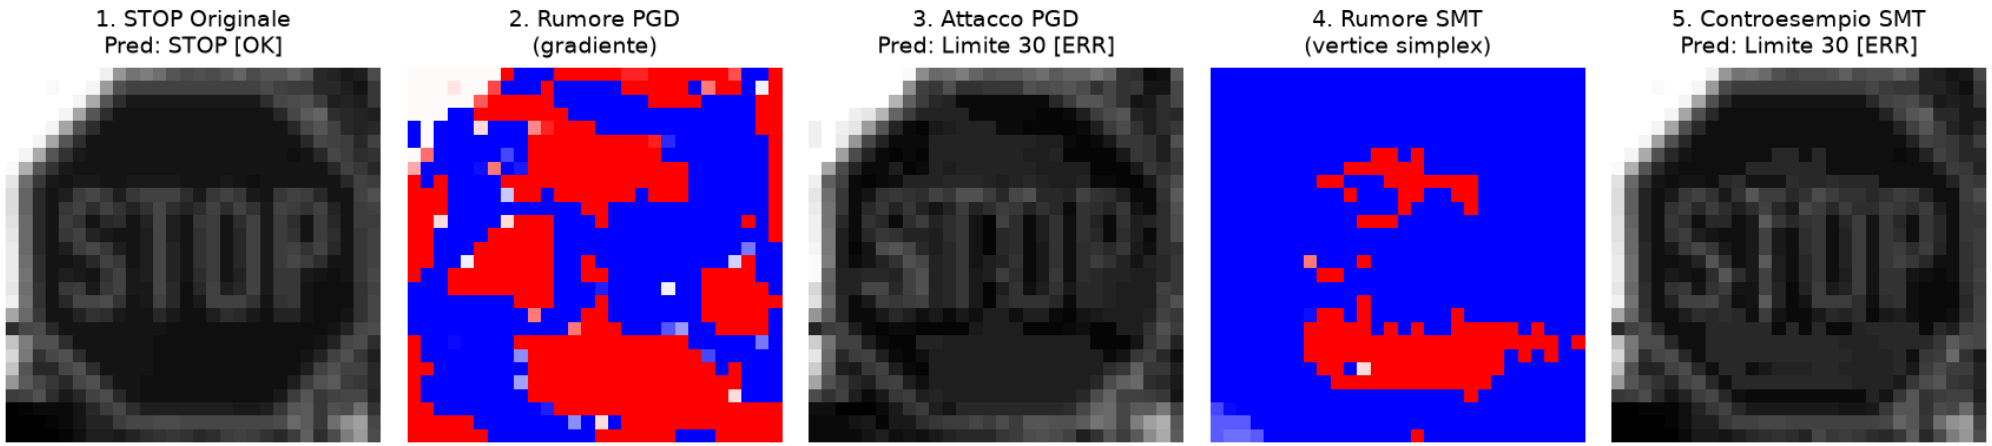
PGD vs Marabou



- **Modello standard**: Marabou certifica che la vera robustezza degrada più in fretta di quanto trovato da PGD (a $\epsilon = 0.05$, 14.8% certificato vs 25.5% empirico).
- **Modello robusto**: a $\epsilon = 0.05$ la certificazione formale (linea tratteggiata) scende al 51.6% a causa dei timeout (24.0%) dovuti all'esplosione combinatoria.
- **Percentuali terminate in verde**: escludendo i timeout, l'accuratezza di Marabou sale al **67.9%**, sovrapponendosi quasi perfettamente alla curva empirica di PGD (68.7%).

Controesempi: PGD vs Marabou

Confronto visivo sul segnale di STOP sotto perturbazione $\epsilon = 0.05$:



- **PGD (euristica)**: induce la pericolosa predizione errata **Limite 30 km/h** tramite rumore diffuso.
- **Marabou (esatto)**: dimostra e calcola il punto continuo esatto sul politopo che scambia anch'esso lo STOP con **Limite 30 km/h**, attestando il vertice del simplesso sul confine di decisione.

Conclusioni

1. **L'adversarial training produce robustezza reale**:
   - Resiste empiricamente a PGD (+43.2% a $\epsilon = 0.05$, da 25.5% a 68.7%).
   - Aumenta direttamente l'accuratezza certificata (+32.4% a $\epsilon = 0.03$, da 40.8% a 73.2%; +36.8% a $\epsilon = 0.05$).
2. **Perché serve la verifica formale**:
   - I test euristici non danno certezze matematiche; Marabou certifica l'inviolabilità o estrae controesempi minimi esatti.
3. **Trade-off**:
   - La verifica esatta SMT su ReLU è NP-completa: ideale per certificare MLP compatti, mentre per CNN complesse si ricorre a rilassamenti convessi incompleti (es. CROWN).

Extra: verifica di un adesivo fisico (adversarial sticker)

Minaccia fisica reale: adesivo 6x6 px al centro dello STOP (4.6% dell'area del cartello):



- **Modello standard (SAT in 0.17s)**: Marabou trova in pochi millisecondi un pattern continuo che inganna la rete, inducendo la predizione **Limite 30**.
- **Modello robusto (UNSAT in 1.8s)**: Marabou dimostra matematicamente l'**assoluta inviolabilità**: nessun adesivo in quell'area può far sbagliare il modello difeso verso Limite 30.

Fonti

- **Verifica formale**: Aws Albarghouthi (2021) — *Introduction to Neural Network Verification*, Foundations and Trends in Programming Languages (arXiv:2109.10317)
- **Solver SMT Marabou 2.0**: Haoze Wu, Guy Katz, Clark Barrett et al. (CAV 2024) — *Marabou 2.0: A Versatile Formal Analyzer of Neural Networks* (arXiv:2401.14461)
- **Verifica con rilassamenti (CROWN)**: Huan Zhang, Tsui-Wei Weng, Pin-Yu Chen et al. (NeurIPS 2018) — *Efficient Neural Network Robustness Certification with General Activation Functions* (arXiv:1811.00866)
- **Adversarial training**: Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, Adrian Vladu (ICLR 2018) — *Towards Deep Learning Models Resistant to Adversarial Attacks* (arXiv:1706.06083)